激光自混频 AI 胶体奶品识别系统

摘要

本作品面向胶体奶品快速、非接触式智能鉴别需求，提出一套基于激光自混频动态光散射与 FPGA 的牛奶智能分类识别系统。系统采用了激光二极管作为光源，激光照射到牛奶样品后，样品中的脂肪球等颗粒进行布朗运动，造成的散射光耦合回半导体激光器中产生自混频效应，微弱的光电信号经过信号调理电路放大后送入 FPGA 内置 XADC 完成数字化采集。区别于传统动态光散射设备将相关曲线用于粒径反演，本系统将上位机采集到的自相关曲线数据进行归一化后直接用于牛奶的样品分类与识别，上位机仅负责对实验数据的采集以及记录。本系统硬件基于 XC7A100TFGG484-2 FPGA 平台，利用上位机采集到的牛奶样品的自相关数据集在 pytorch 代码中完成神经网络训练及定点量化验证，从而将量化模型通过 vivado 工程部署至 FPGA 中，完成多类市售纯牛奶样品测试，本作品实现检测范式由 “测量颗粒粒径”向“胶体样品身份识别”拓展，可应用于乳制品现场筛查、乳液悬浮液鉴别与胶体体系在线表征场景。

关键词：FPGA；激光自混频；动态光散射；数字自相关；胶体指纹；轻量化神经网络；奶品识别

第一部分　作品概述

1.1 系统原理

本系统以半导体激光器、胶体奶品样品池、光电信号调理电路、ADC 与 FPGA 为主要组成。核心是通过 FPGA 中的自相关算法对采集到的信号进行处理，根据得到的自相关曲线，然后通过 FPGA 神经网络进行推理，最后完成对奶品的分类。

系统采用了半导体激光器作为激光源，当激光照射到样品池中的悬浮颗粒后，部分光会被颗粒散射回来，与原来的激光在光源内部相互叠加，产生“自混合干涉”现象；FPGA 对采样序列进行高速数字自相关运算，得到具有样品差异性的光强自相关曲线。对比于传统测粒径方法，系统不再把“粒径数值”作为唯一输出，而是直接将相关曲线构造成固定长度，并由部署在 FPGA 内部的轻量化神经网络完成样品分类。核心数据处理均在片上实现，上位机仅承担对样品自相关数据的采集与记录。该方案兼具非接触检测、低延迟、并行处理和嵌入式集成等特点，可实现从“采集—相关—特征—推理—输出”的闭环识别。

1.2 应用领域

作品首先面向不同品牌或不同配方奶品的快速鉴别，可用于食品现场筛查、批次一致性辅助检测及实验室样品管理。由于系统识别依据来自胶体颗粒运动与粒径分布共同形成的动态散射特征，其方法不局限于牛奶，可向酸奶稀释液、乳饮料、蛋白乳液、纳米悬浮液等胶体体系拓展。进一步结合异常检测或开放集识别，可探索掺杂、变质或配方偏离的快速预警。与需要复杂成像或大型光谱系统的方案相比，本系统以激光器、模拟前端和 FPGA 为核心，具备小型化、实时化和端侧处理潜力，适合食品快速筛查、胶体表征、科研实验及在线质量监测等场景。

1.3 主要技术特点

（1）激光自混频动态光散射采集：利用回返散射光与激光腔内光场相互作用，将胶体颗粒运动引起的光强涨落转换为可采集电信号，结构紧凑；（2）FPGA 高速数字自相关：以硬件延迟存储、并行乘加和累加平均实现多滞后点相关计算；（3）相关曲线指纹化：保留整条自相关曲线的形态、衰减与局部差异，而非仅提取单一粒径参数；（4）片上轻量化 AI：将 pytorch 神经网络代码定点化后部署到 FPGA，完成端侧分类；（5）模块化设计：采集、自相关、特征缓存与通信模块相互解耦，便于扩展新的胶体类别和算法。

1.4 功能与特性

本系统进行了对胶体奶品种类的快速智能识别，通过对光电信号采集、高速数字自相关运算、胶体指纹提取与片上 AI 推理分类，能够直接输出样品类别结果。与传统的粒径反演思路不同，该系统是以完整的自相关曲线作为识别特征。硬件方面自制了一体化 3D 打印结构，携带了样品温控与可调滑轨结构，保障了光路的稳定性。依托 FPGA 硬件并行算力完成核心的运算，而上位机 Labview 仅用于数据记录。实验支持了 5 类胶体样品的识别，INT8 定点量化部署后的精度损失仅 0.64%，单次的检测周期约 1 秒。该系统具备模块化可扩展能力，可拓展更多的胶体样本类别，适配现场筛查、在线表征等嵌入式使用场景。

1.5 主要性能指标

FPGA 工作主时钟为 100MHz，自相关运算共设置了 90 个运算通道，单轮采样点数为 1M，平均迭代次数为 20 次；PC 端浮点模型识别准确率达到 94.57%，FPGA 定点推理准确率能达到 93.93%，单次完整检测耗时 1s；工程 DSP 资源占用了 73.33%；配备样品温控单元，保证检测环境条件一致；可完成 5 类样品的分类识别。系统整体具备抗杂光、抑制机械振动干扰能力，最终识别结果可直接通过 OLED 显示屏输出。

1.6 设计流程

设计流程如下：（1）进行技术方案的调研，确定激光自混频结合 FPGA 端侧 AI 的整体技术路线；（2）完成光学光路、模拟信号的电路设计，自制 3D 打印制作一体化机械装配结构；（3）FPGA 进行信号采集、数字自相关运算；（4）PC 端对采集的自相关指纹数据集完成神经网络训练与 INT8 定点量化；（5）将量化模型部署至 FPGA，进行数值调试；（6）对多类样品开展整机测试验证，迭代优化光路、电路与时序逻辑，最终完成整套系统开发。

第二部分　系统组成及功能说明

2.1 系统概述

如图 2-1 所示，整个系统由“激光光路-信号调理-FPGA 数字处理-结果输出”的链式结构路线组成。温控模块首先将待测奶品的温度保持均衡，恒流源驱动模块为激光二极管提供稳定的电流，当半导体激光器发出的光照射到待测样品，形成的光斑聚集在样品池的中间，使得胶体颗粒产生的后向散射光重新耦合进入激光器腔内，发生自混合干涉，通过激光器中的光电二极管（PD）进行光电探测，输出与参考光发生自干涉的微弱电流信号。该电流信号经过正负电源模块供电的运放放大电路完成信号的增益后，再经过分压模块实施分压、滤波，把信号调整到适合 ADC 采集的范围。FPGA 主控模块以高速的 ADC 数据为输入，执行数据的自相关运算，从的得到自相关分析结果。将归一化后的自相关值作为神经网络的输入，在 FPGA 中完成对奶品类别的推理与分类，最后通过显示模块显示分类的结果。整个系统首尾相接，相互协同，构成一条从光源驱动到神经网络推理分类的高精度，低时延测量链。

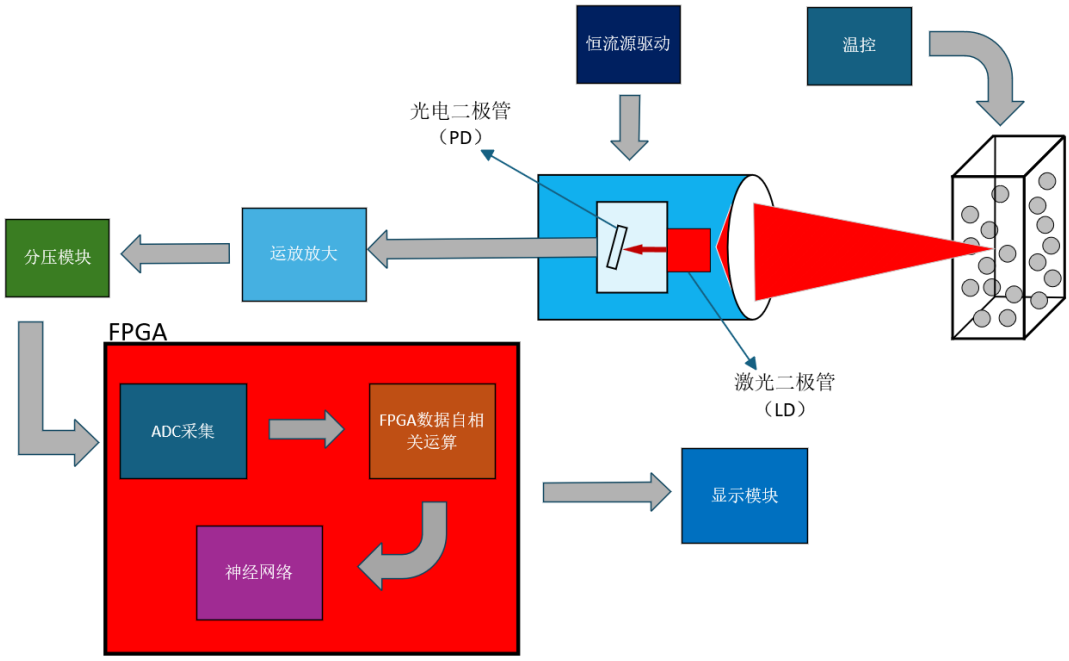


图 2-1 系统框图

2.2 硬件系统整体

如图 2-2，本系统自行通过 3D 打印技术完成了一体化层叠式机械结构，实现光路，样品，电路板的集成化装配。该结构既方便拆装，又确保了光学同轴度和机械强度。

整体结构采用上下分层的模块化排布形式，结构最上层用于安装集成硬件电路板，该电路板上集成电源模块、激光恒流源驱动模块、信号运放放大模块、光电分压调理模块、单片机交互模块以及显示屏模块，各司其职完成系统的稳压供电、半导体激光器恒流驱动控制、

微弱光电自混合信号放大滤波、信号幅度匹配、人机参数交互以及分类结果实时显示等功能，将前端信号调理与交互显示电路集中布置，简化接线布局。上层腔体下方为独立安装空间，用于放置正点原子达芬奇 Pro 开发板，作为整套系统的核心算法硬件载体，接收前端调理完成的光电信号，依托 FPGA 硬件并行特性完成信号同步采集、自相关函数运算、特征提取以及神经网络推理分类，实现奶品类别的识别输出。

在光路调试部分，结构底部设计带有刻度标识的滑动调距滑轨机构，滑轨相邻刻度间隔设置为 3 mm，能够实现半导体激光器与样品池之间距离的精细化连续调节。在实验调试阶段，操作人员可以借助刻度快速改变光程，反复校准光路，保证激光光斑能够精准汇聚在样品池中心位置，使牛奶内部胶体颗粒产生有效的后向散射光并沿原光路反馈回激光谐振腔，产生信噪比优良的激光自混合干涉信号。滑轨左侧独立支架预留定位安装圆孔，作为半导体激光器的固定基座，保证激光器安装同轴度，降低光路偏移带来的信号衰减；滑轨中段设置专用样品池安装位，样品池配套独立散热结构，能够及时带走实验过程中产生的热量，一方面避免温升改变牛奶中蛋白、脂肪颗粒的分散状态，防止颗粒沉降、团聚而干扰检测结果，另一方面抑制温度漂移对半导体激光器输出功率、波长稳定性造成的负面影响，保障实验条件的一致性。

整套 3D 打印结构将光路、样品单元、各类电路分区隔离，紧凑度高，便于整体搬运与现场实验。分层腔体结构天然形成遮光屏障，有效隔绝外界杂散光入射光路，同时提升结构刚度，削弱外界机械振动对光路的扰动，减少噪声引入。该结构充分考虑实验调试需求，激光器、样品池均为可拆卸安装，样品更换便捷，光路参数可以复现，能够支持多批次、多品类奶品样本的对照检测实验，为基于激光自混合效应的牛奶智能分类检测提供稳定可靠的硬件载体。

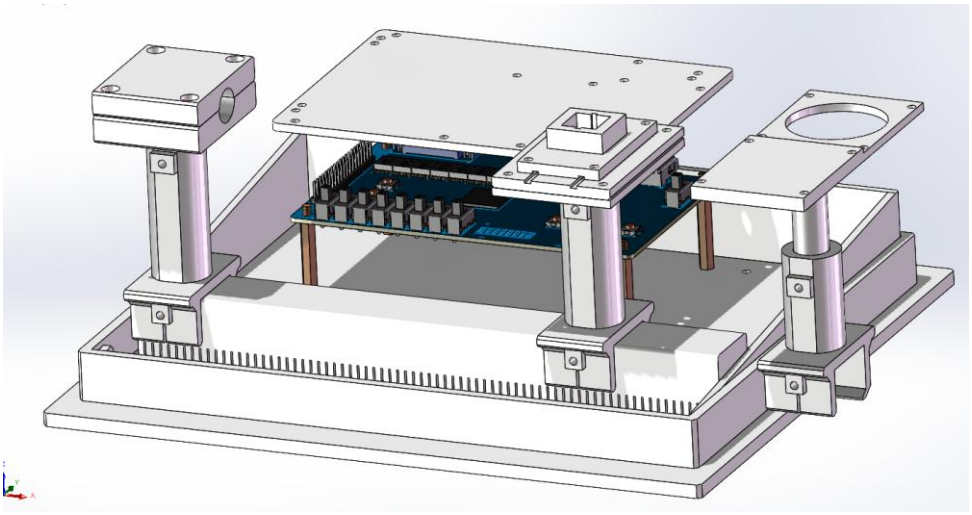


图 2- 2 一体化层叠式机械结构

2.3 电路模块

2.3.1 硬件管理模块

本系统选用正点原子达芬奇 Pro 开发板作为核心运算硬件，其核心芯片为 Xilinx Artix-7 系列 XC7A100TFGG484-2 FPGA。该芯片总计具备 101440 个逻辑单元（Logic Cells），包含 15850 个可配置 Slice，片内集成 240 个 DSP48E1 运算单元，每一个 DSP48E1 单元内部

自带一条 25 bit × 18 bit 硬件乘法器，因此芯片一共搭载 240 路硬件乘法器，专门用于乘累加、卷积、自相关等密集型数值运算任务；同时芯片配置 135 个 36Kb 块 RAM，总 BRAM 容量 4860 Kb，可用于信号缓存、权重参数存储、FIFO 跨时钟域数据交互；片内集成 6 组 MMCM 时钟管理模块，支持多路时钟独立分频、移相，芯片标称最高可稳定运行在 628MHz，在本项目工程中主时钟配置为 100 MHz，可根据流水线时序需求生成不同子时钟域，满足同步采样、并行自相关计算的时序要求 。

在整套牛奶检测装置中，前端 STM32 主控完成光电信号采集与初步调理后，将时序信号传输至该 FPGA 开发板。得益于 240 个 DSP 硬件乘法单元的并行算力，FPGA 可以并行执行多滞后时刻下自相关函数的乘累加运算，大幅缩短自相关曲线的生成耗时；片上 BRAM 资源用于缓存连续采集的激光自混合时序信号、定点量化后的神经网络权重与偏置参数，避免频繁访问外部存储器带来的带宽延迟。FPGA 内部流水线架构配合多路时钟域，依次完成信号同步采样、数据缓存、自相关并行求解、曲线归一化、特征提取，最后调用 DSP 阵列完成神经网络定点推理，输出牛奶样本分类结果。

该开发板采用核心板+底板分离设计，板上配备千兆以太网、SFP 光纤接口、JTAG 调试接口、DDR3 高速内存等外设资源。JTAG 接口支持在线时序抓取、ILA 信号观测，方便在实验阶段调试自相关运算时序、排查定点量化带来的误差；DDR3 内存用于缓存长时序采集数据，适配长时间、多组样本的连续检测实验。硬件布局上，达芬奇 Pro 开发板放置在 3D 打印层叠结构下层腔体，与上层模拟信号调理板物理隔离，降低 FPGA 高速数字运算产生的电磁噪声耦合到微弱光电模拟链路，保障激光自混合信号的信噪比与检测稳定性。充足的逻辑资源、大规模 DSP 乘法阵列与灵活的时钟管理能力，为本系统将物理特征提取、AI 分类决策整合在同一硬件平台提供算力基础。

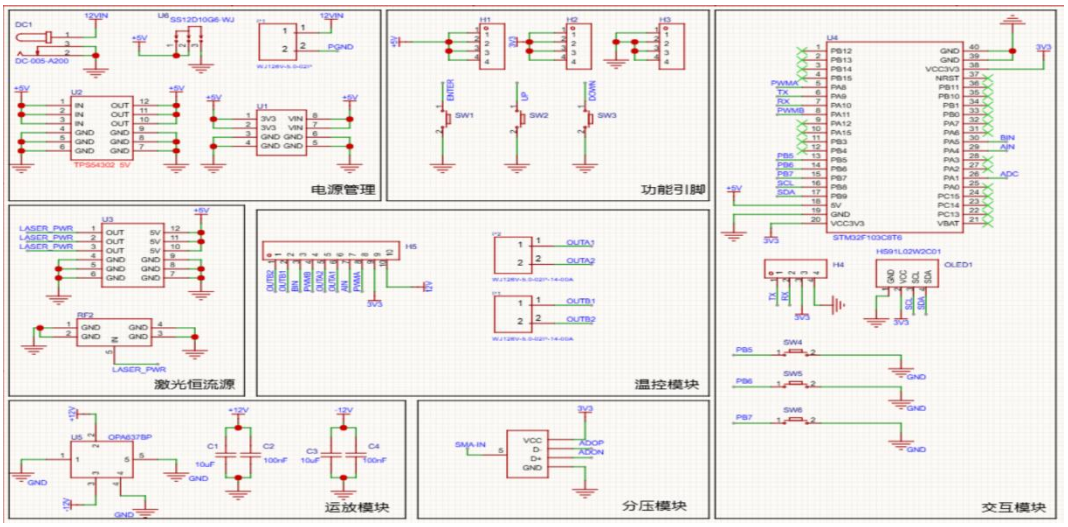


图 2- 3 硬件管理模块

2.3.2 FPGA 主控

如图 2-4，本系统选用了正点原子达芬奇 Pro 开发板作为核心运算硬件，其核心芯片为 Xilinx Artix-7 系列 XC7A100TFGG484-2 FPGA。该芯片总计具备 101440 个逻辑单元,，包含 15850 个可配置 Slice，片内集成 240 个 DSP48E1 运算单元，每一个 DSP48E1 单元内部自带一条 25bit×18bit 硬件乘法器，因此芯片一共搭载 240 路硬件乘法器，专门用于乘累加、卷积、自相关等密集型数值运算任务；同时芯片配置 135 个 36Kb 块 RAM，总 BRAM 容量

4860Kb，可用于信号缓存、权重参数存储、FIFO 跨时钟域数据交互；片内集成 6 组 MMCM 时钟管理模块，支持多路时钟独立分频、移相，芯片标称最高可稳定运行在 628 MHz，在本项目工程中主时钟配置为 100MHz，根据时序需求生成不同子时钟域，满足同步采样、并行自相关计算的时序要求。

DSP48E1 是 FPGA 内部独立的硬件运算硬核，其内部集成了乘法器、加法器以及多路选择器。与普通 LUT 逻辑的乘法电路相比，它乘累加计算时速度更快，不会大量消耗 LUT 资源，非常契合自相关运算、神经网络推理这两大模块的计算需求。从图 2-5 的工程资源报表可以看出，整套设计一共调用了 176 个 DSP 单元，DSP 资源占用率达到 73.33%，LUT 资源占用 25766 个，利用率 40.64%；触发器 FF 占用率 16.93%；BRAM 仅使用 1.5 个，利用率 1.11%；IO 端口与 MMCM 时钟资源占用也保持在较低水平，系统里两处核心计算任务都依靠 DSP 阵列完成：一方面是数字自相关函数的批量乘累加运算，另一方面是轻量化神经网络推理阶段的矩阵乘法运算。依靠这 240 个 DSP 硬件乘法单元带来的并行算力，FPGA 可以同时计算多滞后时刻对应的自相关函数，有效缩短了自相关曲线的生成时间，保障了检测的实时性。

片上 BRAM 用来存放连续采集的激光自混合时序信号、以及定点量化后的神经网络权重与偏置参数，避免频繁访问外部存储器带来的带宽延迟。FPGA 内部流水线架构配合多路时钟域，依次完成信号同步采样、数据缓存、自相关并行求解、曲线归一化、特征提取，最后根据 DSP 阵列完成神经网络的定点推理，完成并输出牛奶样本的分类结果。

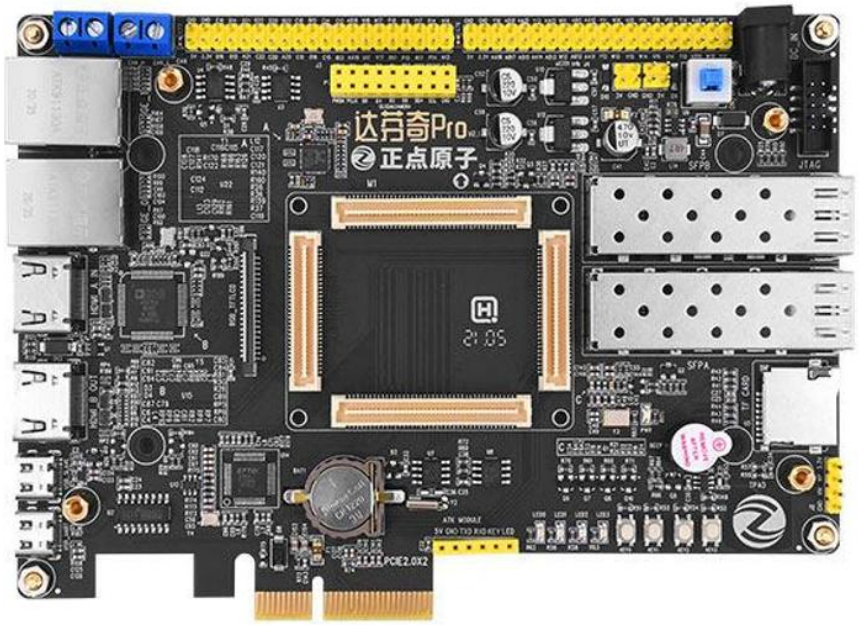


图 2- 4 FPGA 主控

Resource	Utilization	Available	Utilization %
LUT	25766	63400	40.64
FF	21473	126800	16.93
BRAM	1.50	135	1.11
DSP	176	240	73.33
IO	8	285	2.81
MMCM	1	6	16.67

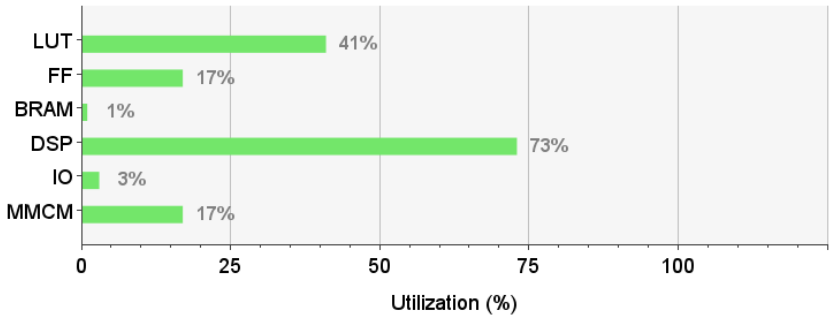


图 2- 5 工程资源报表

2.3.3 正负电源模块

图 2-6 为运放的正负双路稳压电源电路，电路以 5V 直流电压作为输入，采用 XL6008E1 稳压器先将单端 5V 电压变换为+16V 与-16V 两路预稳压电压，再经由 L78M12、L79M12 线性稳压器，输出稳定的+12V、-12V 电压。

XL6008E1 是一款宽电压升压型 DC-DC 芯片，通过分压电阻，电感以及储能滤波电容完成升压，把单 5V 输入转换得到+16V、-16V。其中电容采用大容量电解电容搭配 10nF 陶瓷电容，实施对高低频噪声的滤除，抑制 DC-DC 开关噪声。预生成的+16V 电压送入正压线性稳压器 L78M12CDT-TR，稳压输出+12V；-16V 电压送入负压线性稳压器 L79M12CDT-TP，稳压输出-12V。L78M12 与 L79M12 两个线性稳压器的输入端放了 0.33μF 去耦电容，输出端并联了 100nF 陶瓷电容，从而保持环路的稳定，降低了噪声对微弱的光电信号的干扰。

该电路先通过 DC-DC 电路升高电压，再利用线性稳压器稳定输出电压，这样可以保证运放正常放大微弱的激光自混合交变信号。在本系统中，稳定干净的±12V 电源能够减少电路噪声对信号的影响，从而提高光电信号的采集质量和整体检测的稳定性。

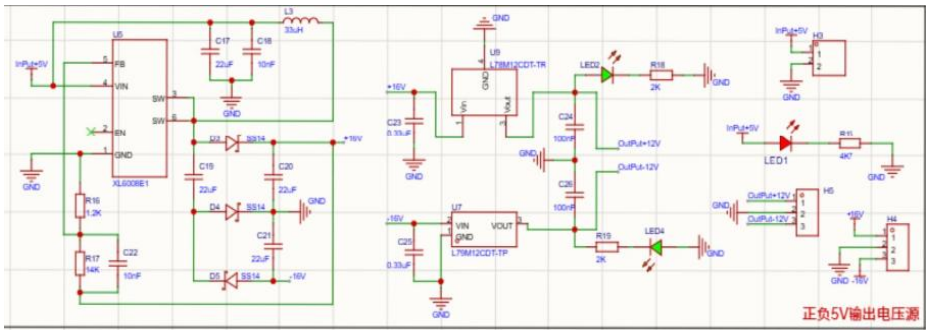


图 2- 6 正负电源模块

2.3.4 运放放大模块

如图 2-7，本模块核心是为 OPA637 运放，分为信号放大电路和供电电路两部分。经过光电探测得到的微弱信号送入运放的反相输入端，从而其中的反馈电阻决定放大的倍数，通过电容来滤除高频率的噪声，防止运放模块自激。供电电路采用±12V 双电源供电，正负电源的引脚都放了 10μF 和 100nF 的并联电容，可以滤除电源引起的高低频干扰，减小供电噪声。

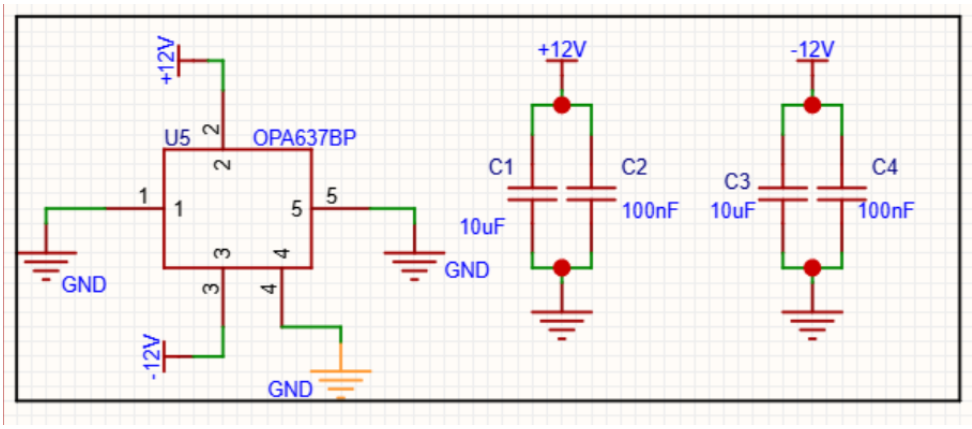


图 2- 7 运放放大模块示意图

2.3.5 温控模块

图 2-8 是用于样品池的温度控制的模块，该模块接收来自 FPGA 输出的 PWM 控制信号，从 H5 接口输入，两个 WJ126V-5.0-02P 连接半导体制冷片，控制制冷片制冷或加热，以此来稳定样品池的温度。模块中 3.3V 为控制信号供电，12V 为功率部分供电，保证每次测量样品时候的温度几乎一致，提高了所测的自相关曲线的稳定性。

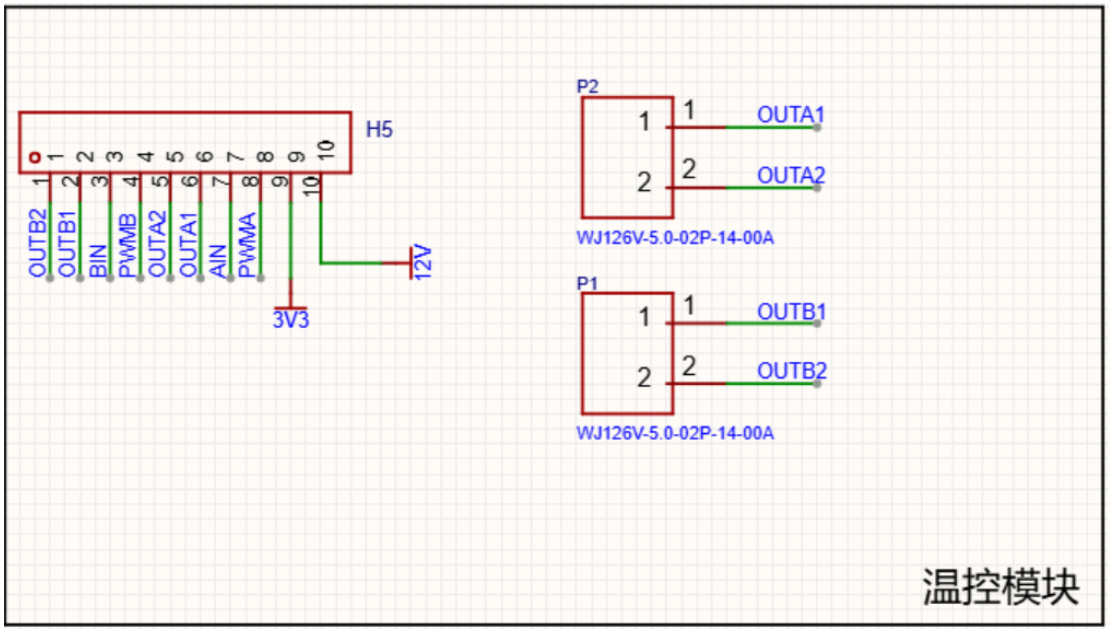


图 2- 8 温度控制示意图

2.4 软件系统介绍

2.4.1 软件整体介绍

软件整体部分分为 Labview 上位机，PC 端 Python-Pytorch 训练量化环境，FPGA 三部分组成。上位机 Labview 仅负责对数据的采集与记录，所有的数据处理与分类推理的核心运算全部包含在 FPGA 硬件内部实现，形成了“采集-数据集成-模型训练量化-硬件部署-片上推理输出”这完整的软件工作体系。

在 PC 端 Python 环境中，基于 PyTorch 框架完成轻量化神经网络的训练与定点量化。将 Labview 导出的自相关曲线数据集做归一化预处理，并划分训练集、验证集与独立测试集，完成神经网络训练，得到浮点精度模型；随后对网络模型实施定点量化，完成量化精度校验，生成适配 FPGA 硬件的定点权重、偏置参数，同时在 PC 侧运行量化后软件模型，输出软件基准识别准确率，用于后续对比验证 FPGA 硬件推理的精度损失。

FPGA 端软件开发依托 Xilinx Vivado 工具完成整体工程搭建。将 PC 端生成的定点网络权重参数导入 Vivado 工程，固化至 FPGA 片上 BRAM/ROM 存储资源。系统实际检测时，FPGA 接收前端调理后的光电信号，硬件完成高速采样、数字自相关运算，直接生成代表奶品特征的胶体光学指纹，对指纹数据归一化后调用片上神经网络推理模块，完成奶品样品分类识别，直接输出类别结果。

2.4.2 FPGA 算法实现

Correlation_Top 是基于 XADC 采集+相关运算+神经网络推理+串口上传的 FPGA 顶层工程，整个工程实施单 100MHz 的同步时钟架构，从而 FPGA 自相关算法被组织成一个单时钟域的流水线。最前端通过 xadc_wiz_0 取样，通过调用 ADC 的 IP 核，然后将差分数据 ipVauxP 和 ipVauxN 送入核内，片内 XADC 每拍都输出 16 位结果，其中的高 12 位经过 assign data_a_from_adc=measAUX2[15:4]变为带符号数据，从而转化成标准的 12 位数字采样数据，代码如下：

```
xadc_wiz_0          Xadc_inst
 (
            .daddr_in                ({2'b00, channel}),
            .dclk_in                 (clk100Mhz),
.....
            .vp_in                    (ipVauxP),
            .vn_in                    (ipVauxN)
);
assign        data_a_from_adc = measAUX2[15:4];
```

核心计算由参数化的 Correlator 模块完成。它以 NUM_OF_CHANNEL=90 来定义 90 个通道，将 ADC 模块的 DataFromADC 写入该模块内部，代码如下：

```
Correlator
#(
      .NUM_OF_CHANNEL (NUM_OF_CHANNEL)
)
Correltor_Inst
```

```
(
    .ipClk                  (clk100Mhz          ),
    .ipRst_                 (ipRst_             ),
    .iData1FromADC          (data_a_from_adc    ),
    .iData2FromADC          (data_a_from_adc    ),
    .iEndOfConversion_1     (endOfConversion_a  ),
    .iEndOfConversion_2     (endOfConversion_a  ),
    .iOrdinal               (ordinal            ),
    .iNumOfAverage          (8'd20),
    .iNumOfdata             (32'd1048576),
    .oMeanOfData            (meanOfData         ),
    .oFrameDone             (frameDone),
    .oMeanOfData_nn         (meanOfData_nn),
    .oDataValid_nn          (dataValid_nn)
);
```

代码表面该工作时钟使用了全局统一的 100MHz 时钟，iData1FromADC 和 iData2FromADC 两路的 ADC 采样输入都接入同一个 data_a_from_adc,从而配置为自相关。将相关运算模块的两路 ADC 转换结束脉冲，统一接入 XADC 模块的转换完成信号 endOfConversion_a，每产生一次脉冲，就代表 FPGA 成功采集到一个全新的 ADC 采样点，该脉冲作为核心的采样同步使能信号，精准驱动相关器抓取实时的采样数据、启动逐点乘积累加运算，保障采样与算法运算的时序完全同步。

算法总共设置了 90 个相关运算通道，通道序号信号与串口组帧模块两者实施同步，实时标记当前正在运算、输出的通道编号，通道序号范围为 0~89，能够严格匹配 90 维特征数据的输出顺序，彻底规避串口传输过程中出现的数据错位、乱序问题，保证上位机解析数据的准确性。算法配置了 20 次迭代平均机制，每个相关通道都会独立完成 20 轮完整运算后再求取最终均值，有效地输出相关谱曲线；同时设定了单轮运算的核心采样参数，以 1048576 个采样点（即 2 的 20 次方、1M 采样点）为单次累加运算基数，通过单个通道先连续采集 1M 个有效 ADC 采样点完成基础自相关乘积累加运算，再循环重复执行 20 轮该累加流程，对多轮运算结果做均值处理，最终输出高精度的 24 位有符号相关均值数据，这样有效抑制了 ADC 采集过程中产生的量化噪声，提升信号特征的精度与稳定性。

当系统完成全部 90 个通道、且每个通道均完成 1M 点累加与 20 次迭代平均的全套运算流程后，相关器模块会输出高电平有效的帧完成脉冲信号，该信号通过串口传输到后端 Uart_data_ready 组帧模块，将 90 维完整信号特征数据全部运算完毕并组帧打包，最终将特征数据交给神经网络，读取特征进行分类。

2.4.3 FPGA 神经网络

FPGA 内部集成的轻量化神经网络采用了流水线架构。网络设置的并行 MAC 数量为 1，即同一个时钟周期内仅能执行一组乘累加（MAC）运算，依靠时间复用这唯一的 MAC 单元完成矩阵乘运算；权重参数采用了 8 位有符号定点 INT8 格式，通过 PC 端量化后得到，之后固化存储在 FPGA 的 ROM 中；内部累加器参与了 32bit 高位宽寄存器进行缓存累加，激活函数采用了 ReLU 实现，通过组合逻辑判断正负、负值置零，从而无需乘法运算，不需要消耗 DSP 的乘法资源；网络各层中间特征数据采用 FPGA 片上 BRAM 缓存，通过分时复用的方式存储中间特征向量，减少了寄存器的数量。代码如下：

```
Neural_network #(
    .IN_FEATURES      (NUM_OF_CHANNEL),
    .OUT_FEATURES     (5),
    .BIT_WIDTH        (8),
    .PARREL           (1),
    .RAW_DATA_W       (24)
)Neural_network_inst(
    .i_clk            (clk100Mhz),
    .i_rst_n          (ipRst_),
    .op_seg_en        (op_seg_en),
    .op_seg_data      (op_seg_data),
    .op_led           (op_led),
    .raw_sig          (meanOfData_nn),
    .raw_valid        (dataValid_nn)
```

代码显示复用了全局 100MHz 系统时钟，和前端 XADC、相关运算属于同一个时钟域，送入神经网络中的原始自相关指纹信号位宽为 24bit，NUM_OF_CHANNEL 定义输入的特征维度，PARREL 并行度参数设置为 1，直接决定并行 MAC 数为 1，RAW_DATA_W 为 24bit，和前端相关器输出的 24bit 自相关均值特征位宽严格匹配。raw_sig 用来接收来自相关器的 24bit 自相关特征，与 raw_valid 作为有效信号，当 raw_valid 为高电平时，神经网络会采样 raw_sig 上稳定的特征数据，防止读取到运算过程中的无效中间值。相关器在通道中依次输出 90 维特征，从而神经网络依靠 valid 的有效信号逐个采集全部的特征向量，特征采集完毕后启动前向推理，推理完成后，通过 4bit 的 op_led 端口直接输出 5 分类识别结果，实现 FPGA 神经网络对样品的识别判定。

2.4.4 Python-Pytorch 训练量化

Python-PyTorch 模块是本系统 PC 端的核心工具，主要工作包含数据集处理、神经网络训练、面向 FPGA 的 INT8 硬件感知量化、硬件行为仿真校验、Verilog 参数头文件自动生成。模块中设计了软硬件算法同源的思路，消除了 PC 浮点模型与 FPGA 定点推理之间的数值差异，从而可以将数据集自动转换成能部署进 FPGA 的模型。该模块根据上位机 Labview 导出的 txt 格式自相关指纹数据集，并依托文件名匹配的标签模式，完成多类样本的标签标注，样本读取完成后对全部数据集进行全局随机打乱，并按照 7:3 的比例划分训练集与测试集。针对 24bit 的原始自相关特征，将数据集进行 Min-Max 归一化处理，从而跨度较大的原始特征映射至 0~255 的无符号 8bit 区间，随后再缩放至[-1,1]浮点区间用于浮点网络的训练。

系统搭建了三层全连接 MLP 轻量化神经网络，输入特征选择了 90 维，依次经过 90→50、50→30 两层全连接层与 HardSigmoid2 非线性激活层，最后通过全连接层输出多类奶品的分类结果。其中根据 HardSigmoid2 不需要复杂的指数运算的优点，将 HardSigmoid2 作为了激活函数，输出范围约束在[-1,+1]，有效降低了硬件资源开销；训练过程采用交叉熵损失函数与 Adam 优化器相结合，设置了批次数量为 8，迭代训练轮数为 50 进行仿真训练。每次的训练过程都实时统计每轮的损失与训练集分类准确率，从而完成浮点模型训练与收敛训练。训练完统计浮点模型与 FPGA 定点仿真模型的准确率，通过比对浮点准确率以及 FPGA 定点准确率，从而评估输入特征量化后的精度损失，保障了 FPGA 神经网络的推理结果与仿真结果保持一致。

第三部分　完成情况及性能参数

3.1 整体介绍

如图 3-1 和 3-2 所示，是我们的系统实物图，整套结构紧凑集成，测量装置轻巧。

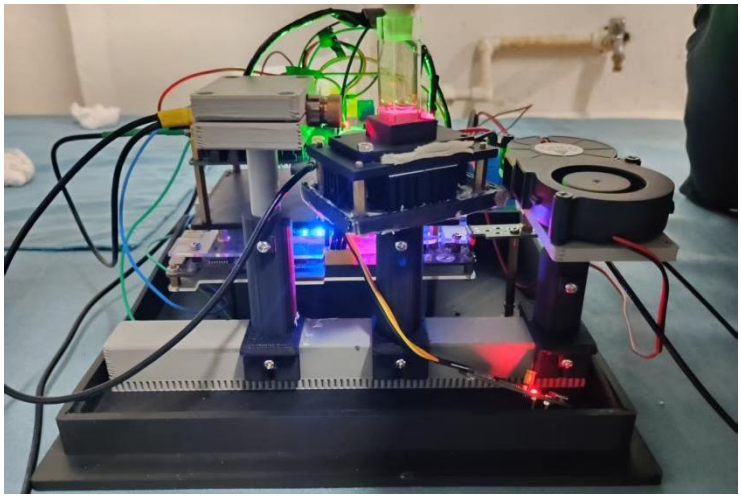


图 3- 1 正视图

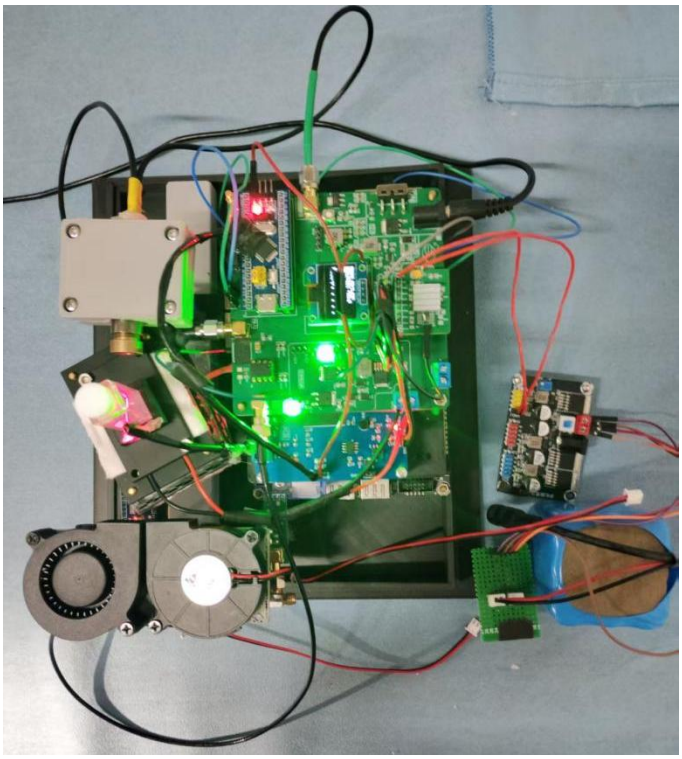


图 3- 2 俯视图

3.2 工程成果

3.2.1 机械成果

如图 3-3 所示为机械结构实物图。

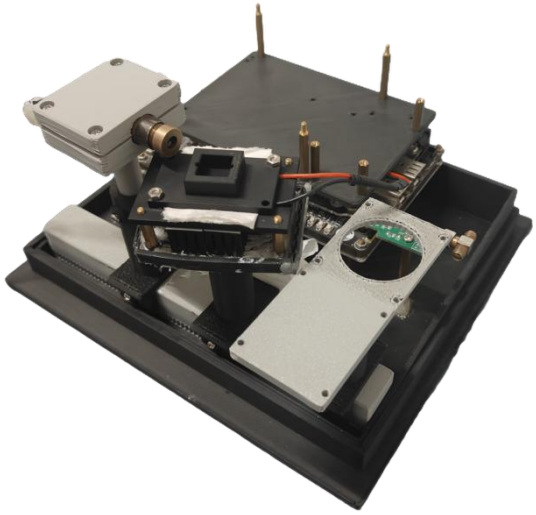


图 3- 3 机械实物图

3.2.2 电路成果

如图 3-4 所示，为整个集成电路的实物图，其中包含了电源开关模块，运放放大模块，分压模块，正负电源模块，单片机交互模块，激光恒流源驱动模块，显示屏显示模块。图 3-5 为 FPGA 主控板。

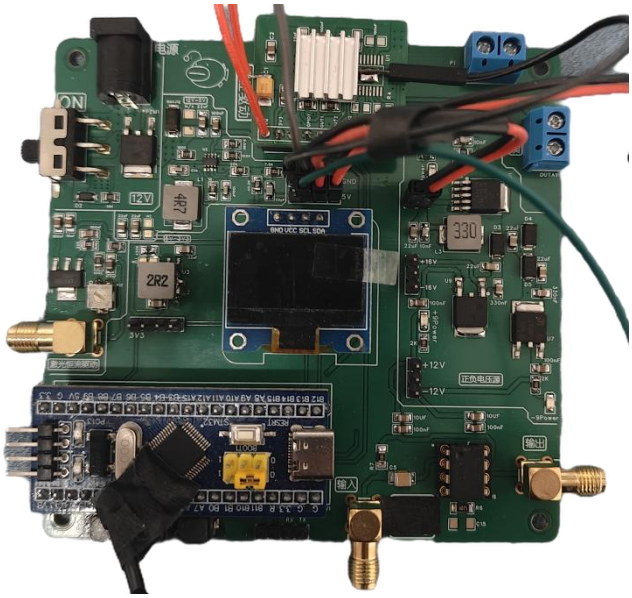


图 3- 4 集成电路实物图

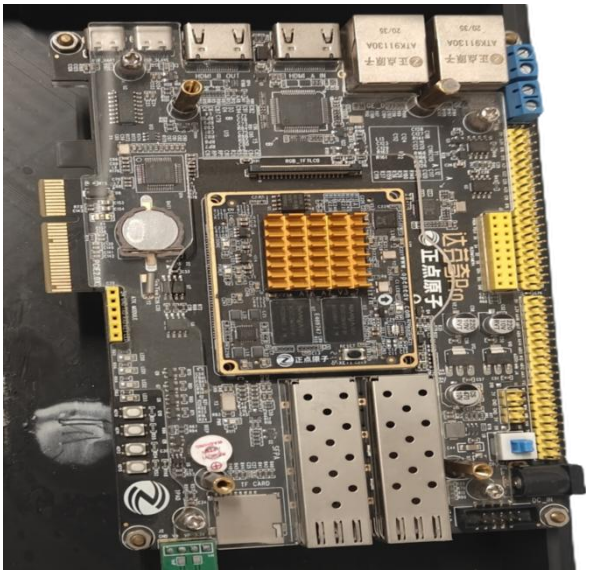


图 3- 5FPGA 主控板图

3.2.3 软件成果

如图 3-6 所示为 Labview 界面图，Correlation time 模块可以实时采集到奶品的自相关曲线，每 1s 完成一次采集与自相关运算，并输出一条自相关指纹曲线，每条曲线相当于 90 个数据点构成，对应了神经网络的 90 个输入通道。采集得到的曲线样本会保存至文本文件，构建出奶品的自相关指纹数据集，用于 PC 端 Python 神经网络训练。

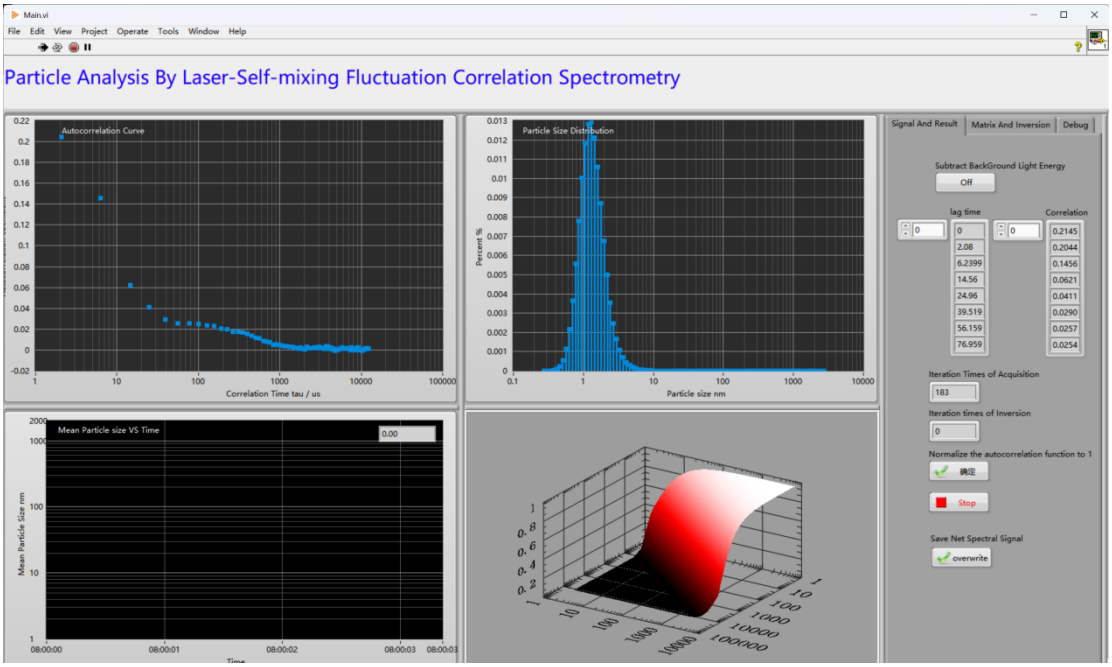


图 3- 6Labview 界面

图 3-7 是在 Pycharm 软件在特定的虚拟环境所构成的 Python 代码界面，对采集得到的自相关指纹曲线数据集进行神经网络训练与量化。

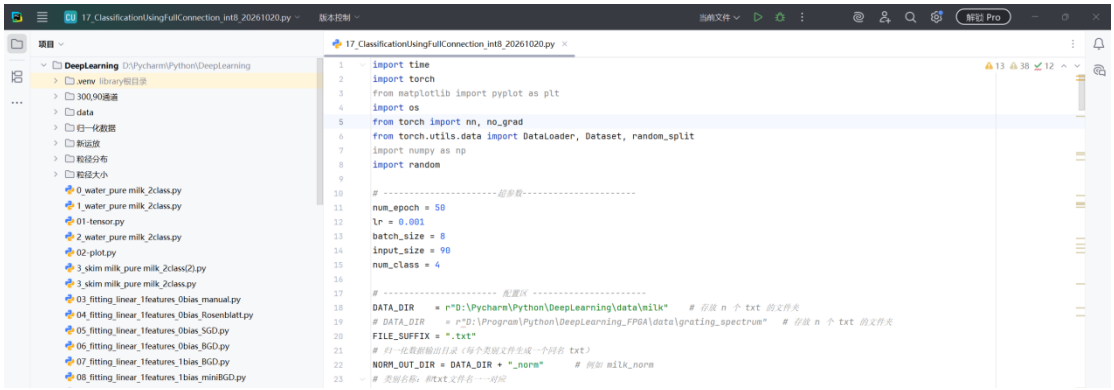


图 3- 7Python 界面

经过 PC 端 Python 神经网络代码训练量化后，将生成的权重与偏置参数文件添加到如图 3-8 所示的 vivado 工程，为 FPGA 神经网络硬件模块提供所需的权重与偏置参数。

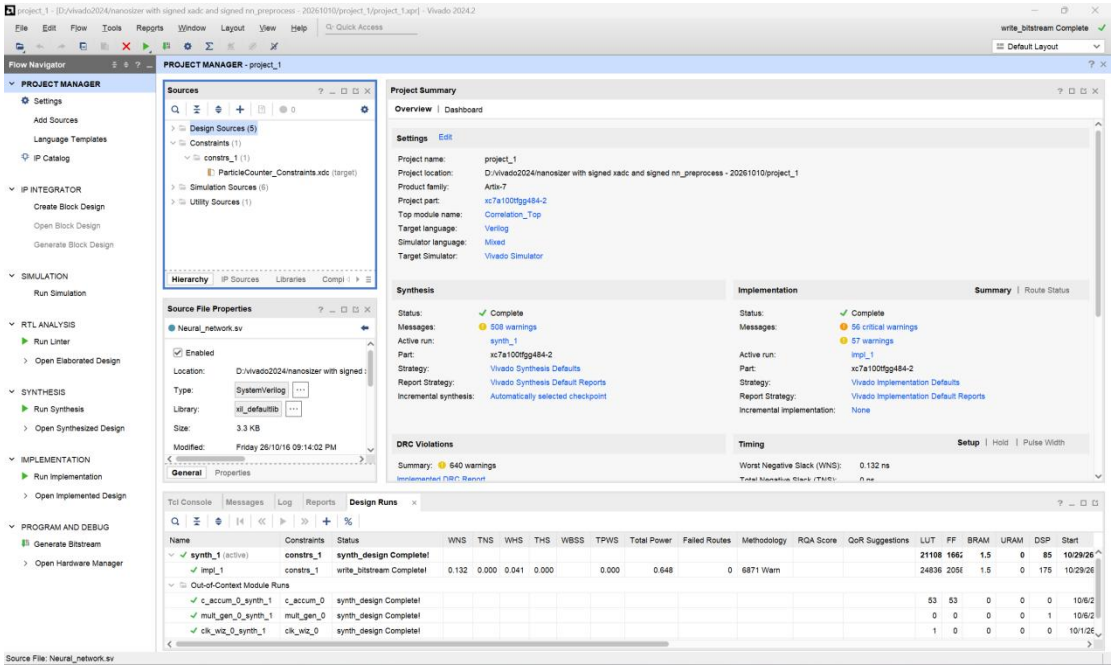


图 3- 8vivado 界面

3.3 特性成果

3.3.1 PC 端训练成果

如图 3-9 为 PC 端 Python 神经网络代码对采集得到的自相关指纹曲线数据集进行训练后得出的结果图，可以看出其中原始数据的浮点准确率可以达到 94.57%,而量化后 FPGA 定点仿真的准确率可以达到 93.93%，量化后的精度损失仅 0.64%，精度损失很小，效果显著。

```
        -124, -124, -124, -127, -125, -124], dtype=torch.int8)
x_int8: tensor([ 127,  117,   62,  -15,  -39,  -50,  -53,  -54,  -56,  -58,  -61,  -63,
         -65,  -68,  -72,  -75,  -80,  -84,  -89,  -92,  -96,  -99, -102, -108,
        -110, -114, -116, -119, -120, -120, -121, -123, -122, -121, -121, -122,
        -121, -122, -123, -121, -122, -123, -122, -123, -124, -123, -125, -124,
        -123, -122, -123, -121, -119, -120, -120, -119, -119, -122, -123, -124,
        -125, -125, -125, -125, -124, -123, -121, -122, -122, -124, -125, -127,
        -127, -125, -126, -123, -122, -120, -121, -121, -121, -123, -125, -123,
        -123, -122, -120, -121, -122, -123], dtype=torch.int8)
x_int8: tensor([ 127,  117,   62,  -15,  -39,  -51,  -56,  -61,  -65,  -70,  -76,  -81,
         -86,  -89,  -92,  -95, -100, -104, -105, -109, -111, -114, -115, -118,
        -120, -122, -122, -123, -123, -123, -125, -125, -125, -124, -124, -123,
        -123, -124, -124, -124, -124, -124, -124, -126, -126, -126, -126, -126,
        -125, -124, -123, -123, -123, -122, -120, -122, -123, -125, -127, -127,
        -127, -125, -124, -124, -125, -124, -126, -127, -126, -127, -127, -127,
        -126, -125, -123, -124, -125, -126, -126, -126, -124, -126, -126, -127,
        -126, -126, -127, -127, -127, -127], dtype=torch.int8)
x_int8: tensor([ 127,  113,   34,  -68, -102, -117, -120, -120, -121, -119, -120, -120,
        -120, -121, -123, -122, -122, -122, -121, -121, -122, -124, -123, -122,
        -121, -123, -124, -124, -124, -123, -124, -124, -125, -123, -124, -125,
        -125, -124, -126, -125, -124, -125, -125, -124, -126, -126, -125, -125,
        -125, -125, -126, -126, -125, -127, -125, -126, -126, -127, -127, -127,
        -126, -127, -127, -127, -126, -125, -126, -127, -126, -127, -125, -127,
        -127, -126, -127, -126, -127, -123, -127, -125, -124, -125, -127, -127,
        -126, -127, -126, -127, -127, -127], dtype=torch.int8)
running time: 0.3037099838256836

FPGA定点准确率: 93.93%
浮点原始准确率: 94.57%
 位宽8/16/17/27bit + 缩放 + HardSigmoid 全部严格对齐FPGA
```

图 3- 9 训练量化结果图

3.3.2 实验成果

本次实验通过神经网络对五种样品进行了分类识别，分别是空样品，单分散 30nm 聚苯乙烯微球颗粒，单分散 200nm 聚苯乙烯微球颗粒,德亚脱脂纯牛奶以及银鹭花生牛奶。如图 3-10，汇总了该五类样品的数据经过归一化处理后所展示的曲线图，由图可以看出，五类样品归一化后的曲线形态具有明显区别。

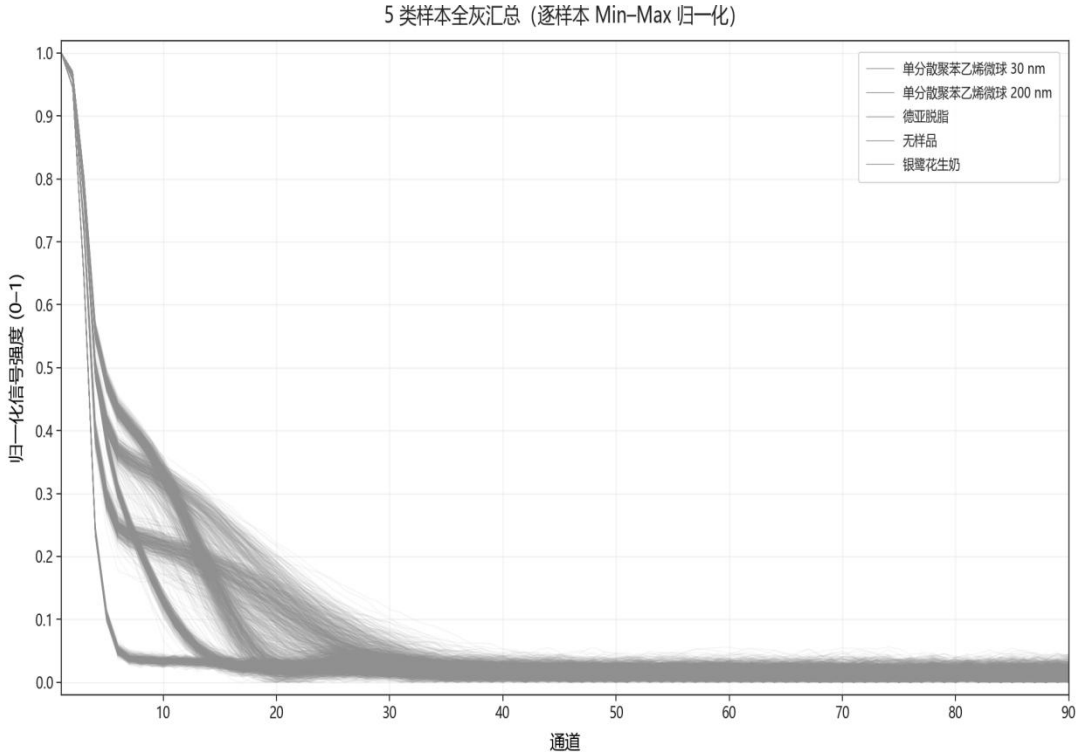


图 3- 10 归一化汇总曲线图

根据样品各自都呈现出独特的变化趋势，我们最后通过神经网络最终进行测试分类，通过显示屏有效区分了空样品，单分散 30nm 聚苯乙烯微球颗粒，单分散 200nm 聚苯乙烯微球

颗粒,德亚脱脂纯牛奶以及银鹭花生牛奶，证明该装置可以实现对颗粒样品的快速检测与分类。实验结果图如 3-11 下所示，



图 3- 11 实验结果图

第四部分　总结

4.1 可扩展之处

对于数据集层面，我们可以扩充到多种品牌，不同储存条件的奶品样本，检测分类的对象也可以拓展到乳制品，稀释酸奶，纳米悬浮液等胶体，还可以拓展到对样品变质情况下进行报警提示。硬件方面，根据 DSP 资源余量充足，可再进一步提升 MAC 并行数量，从而降低神经网络推理的延迟时间，并且可以再优化定点的位宽使得精度更加精确，与资源进一步权衡。算法方面可以引进对多维的光学指纹进行相近样品的分辨，同时还可以优化其中的自相关运算逻辑，提高运算效率。

4.2 心得体会

参与这次 FPGA 比赛，让我收获了很多。从方案调研、硬件搭建、算法开发到整机联合调试，完整经历一套检测系统的开发，我的专业能力和工程实践能力都得到很大提升。 以前我只是学习过 FPGA 基础语法，通过本次项目，我真切体会到硬件并行开发和软件编程思维的不同。FPGA 不能直接把软件算法照搬成 Verilog 代码，需要结合 DSP、BRAM 等硬件资源设计流水线，权衡资源、延迟和精度。本次工程采用单 MAC 分时复用 DSP 硬核实现神经网络推理，让我熟悉了定点量化、乘累加运算、位宽截位等 AI 硬件部署的实际工程要点。 本作品融合光学、模拟电路、信号处理和人工智能多方面知识，也让我明白了硬件对算法的重要性。神经网络识别效果依赖高质量的采集信号，光路偏移、电路噪声、温度变化都会影响自相关曲线，算法无法弥补硬件带来的信号缺陷。调试过程中遇到不少问题，在不断排查光路、电路与时序故障的过程中，锻炼了我逐层分析、定位问题的排错能力。 软硬件数值对齐是项目的一大难点。浮点模型、Python 定点仿真与 FPGA 硬件计算逻辑需要严格保持一致，不能只看最终分类结果，还要比对中间计算结果，排查量化带来的误差，这让我懂得工程开发不能只满足现象正确，计算过程同样要严谨可靠。 同时，撰写参赛报告也锻炼了我们整理实验数据、梳理技术方案的能力。项目还存在部分不足，后续可以补充更多样品测试，完善工程文件。这次参赛积累的软硬件协同开发经验，也为我今后的学习打下了坚实基础。

第五部分　参考文献

(1) 陆敏，王鸣，郝辉. 半导体激光器的自混合散斑干涉测量流体速度[J]. 光学学报，2005(02)：190-194.

(2) 宦海,卢松,张雨,等. 基于 FPGA 的激光自混合干涉信号高速数据处理系统设计 [J]. 科学技术与工程，2016，16 (3)：188-191+206.

(3) 曾彬. 基于 FPGA 激光干涉信号采集与处理[D]. 南京师范大学，2015.

(4) 江静枝. 基于光散射法的颗粒浓度检测系统研制[D]. 东南大学，2018.

(5) 张泽瑞. 基于 FPGA 的动态光散射测量技术研究[D]. 中国计量大学，2020.

(6) 余铭奇. 基于 FPGA 和 DSP 的喷油器雾化粒径检测系统的设计[D]. 华南理工大学，2011.

(7) 钱明. 激光照射纳米流体形成散斑的特性及应用研究[D]. 南京理工大学，2008.

(8) 姬静毅. 激光自混合干涉位移测量系统的设计[D]. 郑州大学，2011

(9) 原洋. 激光自混合干涉测量系统中的 FPGA 信号处理研究[D]. 南京师范大学，2014.

(10)邵静波,王玉兰,王成贵,等. 半导体激光自混频干涉技术在探测器中的应用 [J]. 延边大学学报(自然科学版)，2002，(2)：95-96.

(11)李鲲. 半导体激光器自混频干涉测距技术研究[D]. 北京理工大学，2017.